

Министерство образования Республики Беларусь
Учреждение образования
«Белорусский государственный университет информатики и радиоэлектроники»

Кафедра интеллектуальных информационных технологий

ЛАБОРАТОРНАЯ РАБОТА №2

по дисциплине «Естественно-языковой интерфейс
интеллектуальных систем»

Тема: «Автоматическое распознавание языка текста»

Вариант 23

Выполнил:
студент группы 321701
Духвалов П. Н.

Проверил:
Крапивин Ю. Б.

Минск, 2026

Содержание

1	Цель работы	2
2	Задачи лабораторной работы	2
3	Задание	2
4	Используемые библиотеки и компоненты	3
5	Структура разработанной системы	3
6	Структурно-функциональная схема	4
7	Структуры данных для хранения входной и выходной информации	4
8	Алгоритм определения языка	5
8.1	Алфавитный метод	6
8.2	Метод частотных слов	7
8.3	Нейросетевой метод	8
9	Тестирование системы	9
9.1	Тестовая коллекция	9
9.2	Результаты распознавания	10
9.3	Оценка быстродействия	11
10	Выводы	12

1 Цель работы

Изучить и отработать практические навыки применения методов автоматического распознавания языка текстовых документов.

2 Задачи лабораторной работы

1. Построить тренировочный набор текстов для классифицируемых языков размером от 20 до 120 КБ.
2. Построить профили для классифицируемых языков на основе тренировочного набора текстов.
3. Для каждого входного документа построить профиль и вычислить метрику расстояния до каждого языкового профиля.
4. Выбрать язык с минимальным значением метрики и принять его за результат.
5. Сравнить результаты распознавания различными методами.
6. Реализовать программную систему с пользовательским интерфейсом, средствами сохранения и печати результатов, встроенной справкой.

3 Задание

Согласно варианту 23:

- **Языки текста:** русский, итальянский;
- **Формат документов:** HTML;
- **Реализуемые методы:** частотных слов, алфавитный, нейросетевой.

Требования к системе:

- на входе — текстовые документы одинакового размера (около 1 страницы A4), содержащие тексты на естественных языках;
- на выходе — активная ссылка на документ, результат идентификации и сводная статистика по всем текстам;
- наличие средств сохранения в файл и печати результатов;
- интерфейс доступный, с встроенными help-средствами.

4 Используемые библиотеки и компоненты

Таблица 1 – Библиотеки, использованные в проекте

Библиотека	Назначение
PyQt6	Построение графического интерфейса
BeautifulSoup4	Извлечение текста из HTML-документов
scikit-learn	Нейросетевой классификатор MLPClassifier, векторизация признаков
numpy	Матричные операции для нейросети

Особенности применения готовых компонент:

- **BeautifulSoup4** используется для очистки HTML: удаляются теги `<script>`, `<style>`, `<nav>`, `<footer>`, извлекаются только абзацы и заголовки статьи. Это снимает задачу ручного парсинга вёрстки Википедии.
- **MLPClassifier** из **scikit-learn** реализует многослойный перцептрон с задаваемой архитектурой (`hidden_layer_sizes`) и обучением методом обратного распространения ошибки.
- **DictVectorizer** превращает словари символьных 3-грамм в разреженную матрицу признаков. Это позволяет обучать нейросеть на текстах без ручного отбора признаков.

5 Структура разработанной системы

Система реализована в виде набора модулей (таблица 2). Файлы методов находятся в подпапке `methods/`.

Таблица 2 – Модули системы

Файл	Ответственность
<code>config.py</code>	Константы, пути, список языков
<code>text_utils.py</code>	Извлечение текста из HTML
<code>alphabet.py</code>	Алфавитный метод
<code>frequent_words.py</code>	Метод частотных слов
<code>neural.py</code>	Нейросетевой метод
<code>detector.py</code>	Оркестратор: обучение и определение языка
<code>ui/</code>	Интерфейс, диалоги, справка

6 Структурно-функциональная схема

На рисунке 1 приведена структурно-функциональная схема приложения. Она разделена на три слоя: **представления** (UI), **бизнес-логики** (три метода распознавания и оркестратор) и **хранения** (папки с обучающими и тестовыми HTML-файлами). Пользователь через UI запускает обучение и распознавание, получает результаты в табличном виде и может выгрузить их в CSV или распечатать.




Рисунок 1 – Структурно-функциональная схема

7 Структуры данных для хранения входной и выходной информации

Входная информация. Обучающие и тестовые документы хранятся в виде HTML-файлов в трёх папках:

- data/train_ru/ — 10 обучающих HTML-файлов на русском языке (темы: информационный поиск, машинное обучение, лингвистика и др.);

- `data/train_it/` — 10 обучающих HTML-файлов на итальянском языке (темы: `recupero dell'informazione`, `apprendimento automatico` и др.);
- `data/test/` — 14 тестовых HTML-файлов, по 7 на каждый язык, попарно на одинаковые темы (астрономия, архитектура, живопись, кулинария, космонавтика, океанология, футбол).

Файлы приведены к единому виду функцией `extract_article_text()`: удаляются все HTML-теги, скрипты, навигация, извлекаются только абзацы и заголовки статей.

Внутренние структуры данных. Профили языков хранятся в виде:

- для алфавитного метода — **отсутствуют**; метод не требует обучения;
- для метода частотных слов — словарь `{слово: частота}` для каждого языка, содержащий 300 самых частых слов;
- для нейросетевого метода — обученный объект `MLPClassifier` и `DictVectorizer`, привязанные к классам `ru` и `it`.

Выходная информация. Результаты распознавания представляются в виде таблицы, где для каждого документа указаны:

- имя файла (активная ссылка, открывающая документ в браузере по двойному клику);
- размер в символах;
- результаты трёх методов: предсказанный язык и уверенность;
- эталонный язык, определённый по префиксу имени файла (`ru_` или `it_`).

Сводная статистика содержит точность и среднее время работы каждого метода. Результаты выгружаются в CSV (разделитель `;`, кодировка UTF-8-BOM) и выводятся на печать через `QPrinter`.

8 Алгоритм определения языка

Общая идея всех трёх методов подчинена единому принципу, заимствованному из теории информационного поиска:

1. для каждого языка из конечного набора строится поисковый образ языка (ПОЯ);

2. для входного документа строится поисковый образ документа (ПОД);
3. выбирается стратегия сравнения ПОД и ПОЯ;
4. выносится решение о принадлежности документа определённому языку.

Общий алгоритм приведён на рисунке 2.



Рисунок 2 – Общий алгоритм определения языка

8.1 Алфавитный метод

Метод не требует обучения. Для каждой буквы текста определяется, к какому алфавиту она принадлежит: кириллице или латинице. Язык с наибольшей долей символов объявляется результатом. Уверенность — доля символов «победившего» алфавита среди всех букв.

Метод эффективен только для языков с разными алфавитами (русский и итальянский — именно такой случай). Для пары «французский–итальянский» он бесполезен.

Алгоритм приведён на рисунке 3.




Рисунок 3 – Алгоритм алфавитного метода

8.2 Метод частотных слов

Строится профиль каждого языка — 300 самых частых слов с нормированными частотами. Для тестового документа строится такой же частотный вектор. Расстояние между профилями вычисляется по косинусной мере:

$$\text{sim}(D, L) = \frac{\sum_w f_D(w) \cdot f_L(w)}{\sqrt{\sum_w f_D^2(w)} \cdot \sqrt{\sum_w f_L^2(w)}}, \quad (1)$$

где $f_D(w)$ — нормированная частота слова w в документе, $f_L(w)$ — нормированная частота слова w в профиле языка.

Язык с максимальным значением $\text{sim}(D, L)$ объявляется результатом. Алгоритм приведён на рисунке 4.




Рисунок 4 – Алгоритм метода частотных слов

8.3 Нейросетевой метод

В качестве признаков используются символьные 3-граммы текста, отобранные до топ-500 по частоте. Признаки нормируются и преобразуются в разреженную матрицу признаков. Классификатор — многослойный перцептрон со следующей архитектурой:

- входной слой — число уникальных 3-грамм в обучающей выборке (обычно 1000–3000);
- скрытые слои — 100 и 50 нейронов с активацией ReLU;

- выходной слой — 2 нейрона (языки `ru` и `it`) с softmax;
- функция потерь — cross-entropy;
- оптимизатор — Adam, до 500 итераций.

Вероятность языка вычисляется как:

$$P(L | D) = \text{softmax}(f_{\text{MLP}}(\text{features}(D))), \quad (2)$$

где $\text{features}(D)$ — вектор частот 3-грамм, а f_{MLP} — обученный перцептрон. Язык с максимальной вероятностью объявляется результатом.

Алгоритм приведён на рисунке 5.




Рисунок 5 – Алгоритм нейросетевого метода

9 Тестирование системы

9.1 Тестовая коллекция

Обучающая выборка сформирована из статей Википедии, по 10 на каждый язык. Объём каждой статьи после очистки HTML и обрезки составляет примерно 20–80 КБ, что попадает в диапазон, требуемый в методичке.

Тестовая выборка содержит 14 документов: 7 русских и 7 итальянских, попарно на одинаковые темы. Это позволяет исключить влияние тематики на результат классификации — единственное различие между парами документов это язык.

Соответствие тем приведено в таблице 3.

Таблица 3 – Тематическое соответствие тестовых документов

Тема	Русский	Итальянский
Астрономия	Астрономия	Astronomia
Архитектура	Архитектура	Architettura
Живопись	Живопись	Pittura
Космонавтика	Космонавтика	Astronautica
Кулинария	Кулинария	Cucina
Океанология	Океанология	Oceanografia
Футбол	Футбол	Calcio

Размер каждого тестового документа приведён к 2500 символам (приблизительно одна страница A4) с помощью обрезки по границе предложения.

9.2 Результаты распознавания

Результаты распознавания всех 14 тестовых документов приведены в таблице 4. Все три метода правильно классифицировали все документы тестовой выборки, то есть показали точность 1.000.

Таблица 4 – Результаты распознавания по методам

Метод	Верно	Всего	Точность	Средняя уверенность
Алфавитный	14	14	1.000	0.993
Частотных слов	14	14	1.000	0.629
Нейросетевой	14	14	1.000	0.992

Такой результат объясняется спецификой выбранной пары языков. Русский и итальянский используют разные алфавиты (кириллица и латиница), поэтому алфавитный метод решает задачу безошибочно — уже первой буквы достаточно для уверенного вывода. Частотные профили языков также сильно различаются: наиболее частые слова русского (*и, в, не, на, что*) и итальянского (*il, di, che, e, la*) практически не пересекаются. Нейросетевой метод на символьных 3-граммах также легко различает эти языки, поскольку их морфология и фонетика существенно различаются.

Важно отметить, что уверенность методов различается, хотя точность у всех одинакова. Алфавитный и нейросетевой методы дают уверенность 0.99, тогда как метод частотных слов на коротких текстах (порядка 500 слов) даёт более размытые значения около 0.63. Это связано с тем, что при 300-словном профиле вектор документа содержит относительно мало ненулевых компонент, и косинусная мера недостаточно контрастно разделяет языки. Для повышения уверенности можно увеличить профиль до 500–1000 слов или перейти к логарифмической вероятностной модели (Naïve Bayes с сглаживанием Лапласа), которая даёт более контрастные оценки.

Для проверки различающей способности методов на более сложной задаче целесообразно взять пару языков с одинаковой письменностью — например, французский и итальянский. В этом случае алфавитный метод неприменим, и сравнение будет проходить только между частотным и нейросетевым методами.

9.3 Оценка быстродействия

Результаты замера среднего времени работы каждого метода приведены в таблице 5.

Таблица 5 – Точность и среднее время работы методов

Метод	Точность	Средняя уверенность	Среднее время, мс
Алфавитный	1.000	0.993	0.39
Частотных слов	1.000	0.629	0.22
Нейросетевой	1.000	0.992	1.20

Все методы показали среднее время менее 1.5 мс на документ. Алфавитный и частотный методы работают за доли миллисекунды (0.22–0.39 мс), нейросетевой — около 1.2 мс, что связано с прямым проходом через матрицы MLP. Разница между алфавитным и частотным методами лежит в пределах погрешности измерения, поскольку оба выполняют один линейный проход по тексту.

Время обучения:

- алфавитный — 0 мс (не обучается);
- частотных слов — около 30 мс на построение двух профилей;
- нейросетевой — около 1.5–3 с в зависимости от размера обучающей выборки.

10 Выводы

В ходе лабораторной работы разработана система автоматического распознавания языка текстовых документов, реализующая три метода: алфавитный, частотных слов и нейросетевой.

Основные результаты:

1. Алфавитный метод показал наименьшее время (0.39 мс) и не требует обучения. Для пары «русский–итальянский» точность составила 1.000, что объясняется различием алфавитов. Метод неприменим для языков с одинаковой письменностью.
2. Метод частотных слов дал точность 1.000 при среднем времени 0.22 мс. Однако средняя уверенность метода (около 0.63) ниже, чем у двух других, поскольку косинусная мера на коротких текстах даёт размытые оценки. Увеличение профиля или переход к вероятностной модели позволит повысить контрастность оценок.
3. Нейросетевой метод дал точность 1.000 при времени 1.20 мс. Требует 1.5–3 с на обучение, но устойчив к шуму и работает для языков с одинаковым алфавитом.

Перспективы использования. Система может применяться как учебный стенд для изучения методов распознавания языка. Для практического применения наиболее перспективна гибридная схема: сначала запускается алфавитный метод, и если он даёт уверенный результат, ответ готов; иначе подключается нейросетевой метод. Такая схема даёт максимальную точность при минимальном среднем времени.

Дальнейшее развитие возможно в направлениях:

- расширение списка языков с включением пар с одинаковой письменностью (французский, немецкий, испанский) — это позволит оценить реальную различающую способность методов;
- использование логарифмической вероятностной модели (Naive Bayes с сглаживанием Лапласа) для метода частотных слов;
- переход к нейросетевым архитектурам на символьных эмбедингах (CNN, трансформеры);
- интеграция с системами машинного перевода для автоматического определения языка при переводе.