

Министерство образования Республики Беларусь
Учреждение образования
«Белорусский государственный университет информатики и радиоэлектроники»

Кафедра интеллектуальных информационных технологий

ЛАБОРАТОРНАЯ РАБОТА №3

по дисциплине «Естественно-языковой интерфейс
интеллектуальных систем»

Тема: «Автоматическое реферирование документов»

Вариант 5

Выполнил:
студент группы 321701
Духвалов П. Н.

Проверил:
Крапивин Ю. Б.

Минск, 2026

Содержание

1	Цель работы	2
2	Задачи лабораторной работы	2
3	Задание	2
4	Используемые библиотеки	3
5	Структура разработанной системы	3
6	Структурно-функциональная схема	3
7	Структуры данных для хранения входной и выходной информации	4
8	Алгоритм построения реферата	5
8.1	Классический метод извлечения предложений	6
8.2	Метод TextRank (дополнительный)	7
8.3	Сравнение методов	9
9	Тестирование системы	9
9.1	Тестовая коллекция	9
9.2	Результаты работы	9
10	Выводы	10

1 Цель работы

Освоить на практике основные принципы автоматического реферирования текстовых документов: методы извлечения предложений, вычисление весовых коэффициентов значимости терминов и построение рефератов различных типов.

2 Задачи лабораторной работы

1. Изучить теоретические основы автоматического реферирования: типы рефератов, метод извлечения предложений, весовые коэффициенты значимости терминов.
2. Реализовать классический метод извлечения предложений (sentence extraction) в соответствии с формулами, приведёнными в методических указаниях.
3. Реализовать дополнительный графовый метод TextRank для сравнения подходов.
4. Провести тестирование системы на коллекции документов из предметных областей Computer Science и художественной литературы на русском и итальянском языках.

3 Задание

Согласно варианту 5:

- **Языки текста:** русский, итальянский;
- **Предметные области:** Computer Science, сочинения по литературе;
- **Метод:** sentence extraction.

Требования к системе:

- на входе — текстовые документы одинакового размера (около 10 страниц формата А4) из предметных областей на естественных языках согласно варианту;
- на выходе — активная ссылка на исходный документ и построенный реферат, состоящий из двух разделов: классического реферата и реферата в виде списка ключевых слов;

- наличие средств сохранения в файл и распечатки полученной информации;
- интерфейс должен быть простым и доступным, содержать понятный набор инструментов и help-средства.

4 Используемые библиотеки

Таблица 1 – Библиотеки, использованные в проекте

Библиотека	Назначение
PyQt6	Построение графического интерфейса
rumorphy3	Лемматизация русского языка

Все алгоритмы реферирования реализованы «с нуля» — внешние NLP-библиотеки не используются, чтобы формулы из методических указаний применялись непосредственно.

5 Структура разработанной системы

Система реализована в виде набора модулей:

Таблица 2 – Модули системы

Файл	Ответственность
config.py	Константы, стоп-слова, пути
text_utils.py	Токенизация, лемматизация, фильтрация
corpus.py	Загрузка коллекции, IDF-статистика
extraction.py	Классический метод извлечения предложений
textrank.py	TextRank (дополнительный метод)
summarizer.py	Оркестратор: обработка коллекции
main_window.py	Главное окно приложения
help_dialog.py	Встроенная справка

6 Структурно-функциональная схема

На рисунке 1 приведена структурно-функциональная схема приложения. Она разделена на три слоя: представления (UI), бизнес-логики (мето-

ды реферирования и оркестратор) и хранения (папка с документами коллекции и CSV-отчёты).




Рисунок 1 – Структурно-функциональная схема приложения

7 Структуры данных для хранения входной и выходной информации

Входная информация. Коллекция документов хранится в виде `.txt`-файлов в папке `docs/`. Каждый документ имеет имя вида `ru_cs_01.txt` или `it_lit_02.txt`, что позволяет определить предметную область и язык документа.

Общая структура коллекции:

- `ru_cs_*.txt` — русскоязычные тексты по Computer Science;
- `it_cs_*.txt` — итальянские тексты по Computer Science;
- `ru_lit_*.txt` — русскоязычные сочинения по литературе;
- `it_lit_*.txt` — итальянские сочинения по литературе.

Внутренние структуры данных.

- **Коллекция Corpus** хранит список документов; каждый документ представлен словарём с полями `name`, `path`, `text`, `language`.

- **Статистика TF-IDF** хранится отдельно для каждого языка: частоты терминов в документах (**tf**), максимальная частота (**tf_max**), документная частота (**df**), число документов языка (**N_lang**).
- **Профиль документа** для TextRank — это множество знаменательных слов, извлечённых из предложения.

Выходная информация. Результат обработки каждого документа содержит:

- имя файла и путь к нему;
- язык документа (определён автоматически);
- список ключевых слов с весами;
- классический реферат — список предложений, сохранённых в исходном порядке.

Результаты выгружаются в CSV (разделитель ; , кодировка UTF-8-BOM) и печатаются через `QPrinter`.

8 Алгоритм построения реферата

Общая схема обработки коллекции приведена на рисунке 2.




Рисунок 2 – Общий алгоритм обработки коллекции

8.1 Классический метод извлечения предложений

Метод состоит из трёх этапов.

Этап 1. Вычисляются веса слов документа по формуле:

$$w(t, D) = 0.5 \cdot \left(1 + \frac{tf(t, D)}{tf_{\max}(D)}\right) \cdot \log \left(\frac{|DB|}{df(t)}\right), \quad (1)$$

где $tf(t, D)$ — частота термина t в документе D ; $tf_{\max}(D)$ — максимальная частота термина в документе D ; $df(t)$ — число документов коллекции, содержащих термин t ; $|DB|$ — число документов коллекции того же языка.

Этап 2. Вычисляются веса предложений с учётом положения в документе и абзаце.

Модифицированная TF-IDF-функция:

$$\text{Score}(S_i) = \sum_{t \in S_i} tf(t, S_i) \cdot w(t, D), \quad (2)$$

где $tf(t, S_i)$ — частота термина t в предложении S_i .

Функции положения:

$$\text{Posd}(S_i) = 1 - \frac{BD(S_i)}{|D|}, \quad \text{Posp}(S_i) = 1 - \frac{BP(S_i)}{|P|}, \quad (3)$$

где $|D|$ — число символов в документе; $BD(S_i)$ — число символов до S_i в документе; $|P|$ — число символов в абзаце, содержащем S_i ; $BP(S_i)$ — число символов до S_i в абзаце.

Итоговый вес предложения:

$$\text{Weight}(S_i) = \text{Score}(S_i) \cdot \text{Posd}(S_i) \cdot \text{Posp}(S_i). \quad (4)$$

Этап 3. Предложения сортируются по убыванию веса, из них выбираются топ- N (по умолчанию $N = 10$). Выбранные предложения возвращаются в порядке их следования в исходном тексте.

Алгоритм приведён на рисунке 3.




Рисунок 3 – Алгоритм классического метода извлечения предложений

8.2 Метод TextRank (дополнительный)

TextRank — графовый алгоритм, аналогичный PageRank. Вершины графа — предложения текста, рёбра — косинусное сходство множеств знаменательных слов.

Сходство двух предложений:

$$\text{sim}(S_i, S_j) = \frac{|S_i \cap S_j|}{|S_i \cup S_j|}. \quad (5)$$

Ранги предложений вычисляются итеративно по формуле:

$$R(S_i) = \frac{1-d}{N} + d \cdot \sum_{j \neq i} \frac{\text{sim}(S_i, S_j)}{\sum_k \text{sim}(S_j, S_k)} \cdot R(S_j), \quad (6)$$

где $d = 0.85$ — коэффициент затухания; N — число предложений.

Итерации продолжаются до сходимости (изменение суммы рангов меньше 10^{-6}) или до 30 итераций.

Алгоритм приведён на рисунке 4.




Рисунок 4 – Алгоритм метода TextRank

8.3 Сравнение методов

Таблица 3 – Сравнение методов реферирования

Критерий	Классический метод	TextRank
Принцип	TF-IDF + позиция	Граф сходства предложений
Требует корпуса	Да (IDF по коллекции)	Нет
Учёт позиции	Да	Нет
Учёт IDF	Да	Нет
Языко-независимость	Требует лемматизации	Полная
Скорость	$O(n)$	$O(n^2)$
Устойчивость на коротких текстах	Средняя	Низкая

9 Тестирование системы

9.1 Тестовая коллекция

Коллекция сформирована из открытых источников и содержит 10 документов, по 2–3 на каждую категорию:

- русский Computer Science — 4 документа (научные статьи и статьи Википедии);
- итальянский Computer Science — 2 документа;
- русская литература — 2 документа;
- итальянская литература — 2 документа.

Объём каждого документа — примерно 8 000–30 000 символов. Все файлы в кодировке UTF-8.

9.2 Результаты работы

Для каждого документа программа строит:

- список ключевых слов (20 наиболее значимых терминов с весами);

- классический реферат (10 наиболее информативных предложений, сохранённых в порядке появления в исходном тексте).

Пример результата для документа `ru_cs_01.txt` (классический метод): в реферат попадают предложения, содержащие определения нейронной сети и перечисление ключевых вех её истории (1943, 1958, 1986, 2012), что соответствует основной мысли документа.

Пример результата для того же документа методом TextRank: реферат смещён в сторону предложений с наибольшим лексическим перекрытием с остальным текстом, что на практике даёт более «центральные», но иногда менее структурированные фрагменты.

10 Выводы

В ходе лабораторной работы разработана система автоматического реферирования коллекции текстовых документов, реализующая два метода: классический метод извлечения предложений (по формулам из методических указаний) и TextRank (графовый алгоритм).

Основные результаты:

1. Классический метод извлечения предложений полностью реализован: TF-IDF-веса терминов и функции положения предложений в документе и абзаце вычисляются по приведённым формулам. Веса могут превышать 1, что является следствием логарифмического множителя IDF.
2. Дополнительный метод TextRank позволяет сравнить классический подход с графовым. На коротких документах (до 30 предложений) оба метода дают близкие результаты, на длинных — TextRank показывает большее разнообразие в выборе предложений.
3. Система корректно обрабатывает коллекцию из русскоязычных и итальянских документов, автоматически определяет язык и применяет соответствующие стоп-слова.

Перспективы использования. Система может применяться как учебный стенд для изучения методов автоматического реферирования. Для практического применения перспективны:

- добавление лемматизации итальянского языка через spaCy или FreeLing;
- оценка качества рефератов через ROUGE (сравнение с эталонными рефератами);
- ансамбль методов: объединение предложений, выбранных обоими алгоритмами, для повышения покрытия ключевых идей документа.